

文档清洗回归说明

第一节 可分块文本基底

可分块文本基底指的是在进入 chunking 之前，已经尽量消除了噪音、错误断段和标题漂移问题的正文文本。如果这个阶段的文本本身已经不稳定，后续不管采用普通分块还是父子分块，都只会把错误边界继续向后传递。

为了模拟弱结构 PDF，这一节故意把同一个自然段拆成多行，让句子在视觉上出现被硬切开的效果，但语义上仍然属于同一个自然段。

第二节 人工复核建议 当同一自然段被切成三段以上，或者标题和正文粘连在一起，不要先去调向量参数，而应先回到 parser 和 cleaner 检查输入质量。

如果回答结果频繁引用页眉、页脚、页码或热线号码，通常说明正文抽取边界和噪音清理边界出了问题。

第三节 回归观察点

1. cleaned.md 是否恢复了自然段连续性。
2. documents/chunks/preview 是否仍沿着正确标题边界切分。
3. qa.ask 的引用是否落在正文，而不是落在页眉页脚。